

15-5-2026

Desarrollo Pipeline de Machine Learning Predicción del Nivel de Obesidad.

Dataset: Estimation of Obesity Levels — UCI Machine Learning Repository



Verónica Hernández Alonso
EBIS BUSINESS TECHSCHOOL



INDICE DE CONTENIDOS

1. CONTEXTO DE NEGOCIO Y JUSTIFICACION DEL DATASET	2
Contexto:	2
Dataset seccionado:.....	2
Justificación de la elección:.....	2
2. EXPLORACIÓN Y ANÁLISIS DE LOS DATOS (EDA)	2
Estructura del dataset	2
Estadística descriptiva	3
Distribución de la variable objetivo	3
Histogramas de variables numéricas.....	4
Correlaciones entre variables numéricas	4
Boxplots: Peso y Edad por nivel de obesidad	5
Variables categóricas.....	5
3. PREPROCESAMIENTO E INGENIERIA DE VARIABLES	6
División Train / Test	6
4. SELECCIÓN DE VARIABLES.....	6
5. MODELADO SUPERVISADO – CLASIFICACIÓN MULTICLASE	7
Matriz de Confusión — Random Forest.....	8
6. REDUCCIÓN DE DIMENSIONALIDAD - PCA.....	9
7. ANALISIS NO SUPERVISADO – K-MEANS CLUSTERING.....	9
8. RESULTADOS FINALES Y CONCLUSIONES	10

1. CONTEXTO DE NEGOCIO Y JUSTIFICACION DEL DATASET

CONTEXTO:

Una clínica de nutrición y medicina preventiva solicita un sistema de apoyo a la decisión que permita clasificar automáticamente el nivel de obesidad de sus pacientes en función de sus hábitos alimentarios, condición física y datos demográficos. El objetivo es anticipar riesgos de salud y personalizar las intervenciones médicas.

DATASET SECCIONADO:

Estimation of Obesity Levels Based on Eating Habits and Physical Condition (UCI Machine Learning Repository). Contiene 2,111 registros de personas de Mexico, Peru y Colombia con 16 variables sobre hábitos alimentarios, actividad física y datos personales, y una variable objetivo con 7 niveles de clasificación de peso (desde Insufficient_Weight hasta Obesity_Type_III).

JUSTIFICACIÓN DE LA ELECCIÓN:

- Relevancia clínica: La obesidad es uno de los principales factores de riesgo cardiovascular y metabólico a nivel global. Un clasificador automático tiene aplicación directa en sistemas de triaje y seguimiento de pacientes.
- Complejidad técnica: Mezcla de variables numéricas y categóricas, 7 clases objetivo con distribución relativamente balanceada, y variables con relaciones no lineales.
- Riqueza del dataset: Combina factores de comportamiento (FAVC, CAEC, CALC), físicos (Height, Weight, FAF) y demográficos (Age, Gender), lo que permite un análisis multidimensional completo.



2. EXPLORACIÓN Y ANÁLISIS DE LOS DATOS (EDA)

ESTRUCTURA DEL DATASET


Característica	Detalle
Registros totales	2,111
Variables predictoras	16 (7 numéricas, 9 categóricas)
Variable objetivo	NObeyesdad — 7 clases ordinales
Valores nulos	Ninguno (0 missing values)
Datos sintéticos	Parte del dataset generada con SMOTE para balanceo

ESTADÍSTICA DESCRIPTIVA


	Age	Height	Weight	FCVC	NCP	CH2O	FAF	TUE
Count	2111.000000	2111.000000	2111.000000	2111.000000	2111.000000	2111.000000	2111.000000	2111.000000
Mean	24.312600	1.701677	86.586058	2.419043	2.685628	2.008011	1.010298	0.657866
Std	6.345968	0.093305	26.191172	0.533927	0.778039	0.612953	0.850592	0.608927
Min	14.000000	1.450000	39.000000	1.000000	1.000000	1.000000	0.000000	0.000000
25%	19.947192	1.630000	65.473343	2.000000	2.658738	1.584812	0.124505	0.000000
50%	22.777890	1.700499	83.000000	2.385502	3.000000	2.000000	1.000000	0.625350
75%	26.000000	1.768464	107.430682	3.000000	3.000000	2.477420	1.666678	1.000000
max	61.000000	1.980000	173.000000	3.000000	4.000000	3.000000	3.000000	2.000000

DISTRIBUCIÓN DE LA VARIABLE OBJETIVO

Distribución de niveles de obesidad. Las clases están razonablemente balanceadas (272–351 registros por clase)




HISTOGRAMAS DE VARIABLES NUMÉRICAS




CORRELACIONES ENTRE VARIABLES NUMÉRICAS

Matriz de correlación. Se observa alta correlación entre Weight y BMI (esperada), y correlación moderada de Age con otras variables




BOXPLOTS: PESO Y EDAD POR NIVEL DE OBESIDAD

Boxplots de Peso y Edad por nivel de obesidad. El peso discrimina claramente entre clases; la edad muestra menos separación



VARIABLES CATEGÓRICAS



3. PREPROCESAMIENTO E INGENIERIA DE VARIABLES

- **Sin valores nulos:** El dataset no contiene missing values, por lo que no se aplica imputación.
- **Variables binarias (LabelEncoder):** Gender, family_history_with_overweight, FAVC, SMOKE, SCC — codificadas como 0/1.
- **Variables ordinales (OrdinalEncoder):** CAEC y CALC presentan un orden natural (no > Sometimes > Frequently > Always) que se preserva con codificación ordinal.
- **Variables nominales (One-Hot Encoding):** MTRANS (medio de transporte) no tiene orden, se codifica con get_dummies (drop_first=True para evitar multicolinealidad).
- **Ingeniería de features — BMI:** Se calcula el Índice de Masa Corporal ($\text{Weight}/\text{Height}^2$). Aunque el target lo captura indirectamente, el BMI es una feature clínicamente interpretable y mejora la capacidad predictiva del modelo.
- **Escalado (StandardScaler):** Se aplica normalización estándar (media=0, std=1) sobre el conjunto de entrenamiento y se transforma el test. Es obligatorio para modelos sensibles a escala como Regresión Logística y SVM.
- **Variable objetivo (mapeo ordinal):** Las 7 clases se mapean a enteros 0–6 respetando el orden natural del nivel de obesidad.


DIVISIÓN TRAIN / TEST

Se realiza una división estratificada 80% entrenamiento / 20% test (random_state=42). La estratificación garantiza que la proporción de cada clase se mantiene en ambos conjuntos, lo que es especialmente importante en problemas multiclase.

4. SELECCIÓN DE VARIABLES

Se entrena un Random Forest preliminar para obtener la importancia media de cada variable (medida como la reducción media en impureza de Gini). Se eliminan las variables con importancia menor al 1%, reduciendo el espacio de features y eliminando ruido.


Importancia de variables. Weight, BMI, Height y Age dominan la predicción. Las variables en gris (< 3%) aportan menos, pero se mantienen si superan el 1%. Variables. Seleccionadas: BMI, Weight, FCVC, Age, Height, Gender.



5. MODELADO SUPERVISADO – CLASIFICACIÓN MULTICLASE

Se comparan cuatro algoritmos de clasificación mediante validación cruzada estratificada (5-Fold StratifiedKFold, random_state=42) y se evalúa el rendimiento final en el conjunto de test.

Modelo	Tipo	Parámetros clave	Requiere escala
Logistic Regression	Lineal	max_iter=2000	Si
Random Forest	Ensemble (Bagging)	n_estimators=200	No
Gradient Boosting	Ensemble (Boosting)	n_est=150, lr=0.1, depth=4	No
SVM	Kernel (RBF)	C=10, gamma=scale	Si




Modelo	CV Accuracy	CV Std	Test Accuracy	Macro F1
Logistic Regression	0.9165	±0.0170	0.9078	0.9057
Random Forest	0.9899	±0.0040	0.9858	0.9855
Gradient Boosting	0.9757	±0.0073	0.9858	0.9859
SVM	0.9431	±0.0063	0.9314	0.9297

Mejor modelo: Random Forest con Test Accuracy = 98.58% y Macro F1 = 98.55%.

MATRIZ DE CONFUSIÓN — RANDOM FOREST

Matriz de confusión del mejor modelo. Las predicciones erróneas son mínimas y se concentran en clases adyacentes (confusiones clínicamente lógicas)




CLASSIFICATION REPORT

	precisión	recall	F1-score	support
Insufficient_Weight	1.00	0.98	0.99	54
Normal_Weight	0.98	0.98	0.98	58
Overweight_Level_I	0.97	0.98	0.97	58
Overweight_Level_II	0.98	0.98	0.98	58
Obesity_Type_I	1.00	1.00	1.00	70
Obesity_Type_II	0.98	0.98	0.98	60
Obesity_Type_III	0.98	0.98	0.98	65
accuracy				423
macro avg	0.99	0.99	0.99	423
weighted avg	0.99	0.99	0.99	423

6. REDUCCIÓN DE DIMENSIONALIDAD - PCA

Se aplica Análisis de Componentes Principales (PCA) sobre el conjunto completo normalizado. PCA permite (1) visualizar la separabilidad de las clases en baja dimensión, (2) identificar cuanta información se puede comprimir y (3) proporcionar una representación reducida para clustering.




Izquierda: Scree Plot mostrando que 15 componentes explican el 90% de la varianza. Derecha: proyección 2D coloreada por clase — se observa buena separación de extremos (Insuficiente y Obesidad III)


Con 15 componentes principales se retiene el 90% de la información original. La proyección 2D muestra separación clara entre los extremos del espectro de obesidad, con mayor solapamiento en los niveles intermedios, lo que es coherente con la naturaleza continua del problema

7. ANALISIS NO SUPERVISADO – K-MEANS CLUSTERING

K-Means se aplica sobre las 5 primeras componentes principales para descubrir agrupaciones naturales en los datos sin usar las etiquetas. Se usa el método del codo y el Silhouette Score para determinar el número óptimo de clusters.



Método del codo y Silhouette Score. El valor óptimo es $k=9$ (Silhouette = 0.2669).



Los 9 clusters identificados por K-Means. Los centroides (X negras) muestran posiciones en el espacio de componentes principales

Con $k=9$ clusters se obtiene un Silhouette Score de 0.2669, lo que indica una separación moderada-buena. Los clusters identificados se alinean parcialmente con los grupos de peso del dataset, validando que existe estructura natural en los datos. El número de clusters superior al de clases etiquetadas sugiere que hay sub perfiles dentro de algunas categorías.

8. RESULTADOS FINALES Y CONCLUSIONES

MEJOR MODELO
Random Forest
98.6% accuracy

Macro F1
98.5%
7 clases

PCA
15 comp.
De varianza

CLUSTERS
9
Sil=0.267

- **Rendimiento supervisado excepcional:** Random Forest y Gradient Boosting alcanzan un 98.6% de accuracy en test con Macro F1 > 98%. Esto indica que los hábitos alimentarios y la condición física son variables altamente predictivas del nivel de obesidad.
- **Variables más relevantes:** El peso (Weight), el BMI calculado, la altura (Height), el historial familiar y la edad son los predictores dominantes. Variables de comportamiento como la frecuencia de comida entre comidas (CAEC) y la actividad física (FAF) tienen importancia secundaria pero estadísticamente significativa.
- **Reducción de dimensionalidad:** 15 componentes principales bastan para explicar el 90% de la varianza. La proyección 2D confirma la separabilidad de clases extremas y el solapamiento esperable en niveles intermedios.
- **Estructura no supervisada:** K-Means identifica 9 clusters naturales en los datos (Silhouette=0.267), validando que existe estructura latente en el dataset mas allá de las 7 etiquetas oficiales.
- **Recomendación para producción:** Se recomienda desplegar el modelo Random Forest como clasificador principal, con un umbral de confianza configurable para escalar a revisión manual los casos ambiguos entre clases adyacentes. El pipeline es reproducible y escalable.